**Mini Project 1: การจำแนกประเภท (Classification)**

**สมาชิกกลุ่ม**

6609540015 นางสาวธนพร ทองศรีจันทร์
6609612012 นางสาวธัญลดา สัมพันธ์ไพศาลสุข

**บทนำ**

โครงงานนี้มีวัตถุประสงค์เพื่อศึกษาการประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) สำหรับการจำแนกประเภทของข้อมูล โดยได้มีการเลือกใช้ชุดข้อมูลเกี่ยวกับประเภทของเห็ดที่ประกอบไปด้วยข้อมูลลักษณะทางกายภาพของเห็ดหลากหลายชนิด เช่น รูปร่างหมวกเห็ด สี กลิ่น ลักษณะของครีบ และลักษณะของก้าน เป้าหมายของการใช้ชุดข้อมูลดังกล่าวมีเพื่อจำแนกเห็ดออกเป็นสองประเภท ได้แก่ เห็ดที่สามารถรับประทานได้ (Edible) และเห็ดที่มีพิษ (Poisonous) การจำแนกประเภทของเห็ดเป็นปัญหาที่มีความสำคัญในด้านความปลอดภัยในการบริโภค เนื่องจากเห็ดบางชนิดมีลักษณะคล้ายคลึงกันแต่มีระดับความเป็นพิษแตกต่างกันอย่างมาก การนำเทคนิคการเรียนรู้ของเครื่องมาใช้สามารถช่วยสร้างแบบจำลองที่สามารถทำนายประเภทของเห็ดได้อย่างแม่นยำมากขึ้นจากคุณลักษณะทางกายภาพของเห็ด

การดำเนินงานประกอบไปด้วยขั้นตอนการเตรียมข้อมูล การแปลงข้อมูล การเลือกคุณลักษณะ การสร้างแบบจำลองสำหรับการจำแนกประเภท รวมไปถึงการประเมินประสิทธิภาพของแบบจำลองแต่ละชนิด ในขั้นตอนแรกได้มีการทำความสะอาดข้อมูลเพื่อปรับปรุงข้อมูลให้อยู่ในรูปแบบเดียวกันและพร้อมสำหรับการนำไปวิเคราะห์ ต่อมาได้มีการแปลงข้อมูลให้อยู่ในรูปแบบที่สามารถนำไปใช้กับแบบจำลองชนิดต่าง ๆ ได้ เช่น การแปลงข้อมูลประเภทหมวดหมู่ให้เป็นค่าตัวเลขด้วยวิธี Label Encoding และได้ทำการวิเคราะห์ความสำคัญของคุณลักษณะ (Feature Importance) รวมถึงใช้เทคนิคการเลือกคุณลักษณะ (Feature Selection) เช่น Recursive Feature Elimination (RFE) เพื่อลดจำนวนตัวแปรที่ไม่จำเป็นและเลือกเฉพาะคุณลักษณะที่มีผลต่อการจำแนกมากที่สุด และแบ่งข้อมูลออกเป็นชุดข้อมูลสำหรับการฝึก (Training Set) และการทดสอบ (Testing Set) จากนั้นจึงนำข้อมูลที่ผ่านการคัดเลือกคุณลักษณะไปใช้กับเทคนิคการจำแนกประเภทหลายรูปแบบ เช่น การจำแนกประเภทโดยอาศัยเพื่อนบ้าน (K-Nearest Neighbors classifier: kNN), การจำแนกประเภทแบบ XGBoost (eXtreme Gradient Boosting classifier) และเครือข่ายประสาท (Neural Network) เพื่อเปรียบเทียบประสิทธิภาพของแต่ละโมเดล โดยใช้ตัวชี้วัดต่าง ๆ เช่น Accuracy, Precision, Recall และ F1-score ในการประเมินผลลัพธ์ของแบบจำลอง ผลลัพธ์ที่ได้จากการทดลองจะช่วยแสดงให้เห็นว่าแบบจำลองใดมีประสิทธิภาพเหมาะสมที่สุดสำหรับการจำแนกประเภทของเห็ดจากชุดข้อมูลนี้

**คำอธิบายเกี่ยวกับข้อมูล (Dataset Description)**

**Mushroom Classification** เป็นชุดข้อมูล (Dataset) เกี่ยวกับการจำแนกประเภทของเห็ดซึ่งมีแหล่งที่มาจาก UCI Machine Learning Repository ภายในชุดข้อมูลประกอบด้วยคำอธิบายของตัวอย่างสมมติที่สอดคล้องกับเห็ดมีครีบ 23 ชนิดในวงศ์เห็ด Agaricus และ Lepiota โดยที่ดึงมาจากคู่มือภาคสนาม

ของสมาคม Audubon เกี่ยวกับเห็ดในอเมริกาเหนือปี 1981 (UCI, 2016) ข้อมูลส่วนใหญ่ถูกจัดอยู่ในรูปแบบหมวดหมู่ (Categorical) โดยมีคุณสมบัติหลายตัว เช่น สี ขนาด รูปร่าง และพื้นผิวของเห็ดแต่ละชนิด ซึ่งเหมาะสำหรับการใช้ฝึกโมเดลเพื่อจำแนกชนิดของเห็ดที่บริโภคได้ (Edible) และเห็ดที่บริโภคไม่ได้/มีพิษ (Poisonous)

ผลลัพธ์ที่ได้จากการวิเคราะห์ข้อมูลสามารถใช้ในการศึกษาเกี่ยวกับคุณลักษณะของเห็ดที่ปลอดภัยต่อการบริโภคหรือเห็ดที่มีแนวโน้มว่าจะเป็นพิษ นอกจากนี้การศึกษาข้อมูลดังกล่าวยังมีประโยชน์สำหรับการสร้างระบบช่วยตัดสินใจว่าปลอดภัยต่อการบริโภคหรือไม่ การทดลองกับการเลือกคุณลักษณะ การเรียนรู้การจัดการกับข้อมูลเชิงหมวดหมู่ รวมถึงการใช้งานกับอัลกอริทึมการจำแนกประเภทและตัดสินใจ เช่น Random Forest, XGBoost เป็นต้น

ข้อมูลมีทั้งหมด 8,124 ตัวอย่าง และ 23 คอลัมน์ โดย 22 คอลัมน์เป็นคุณลักษณะของเห็ด (Features) และ 1 คอลัมน์เป็นตัวแปรเป้าหมาย (Target Variable) คือประเภทของเห็ด (มีพิษ/ไม่มีพิษ) โดยข้อมูลแต่ละคอลัมน์เป็นข้อมูลเชิงหมวดหมู่ (Categorical Data) ที่ถูกแทนค่าด้วยตัวอักษรเพื่อแสดงลักษณะเฉพาะของเห็ดในแต่ละด้าน สามารถจัดกลุ่มตามคุณลักษณะต่าง ๆ ได้ดังนี้

**1. Target Variable** ตัวแปรเป้าหมายใช้สำหรับระบุประเภทของเห็ด

- class (ประเภทของเห็ด)

| ค่า | ความหมาย |
|---|---|
| e | edible (เห็ดรับประทานได้) |
| p | poisonous (เห็ดมีพิษ) |

**2. Cap Characteristics (ลักษณะของหมวกเห็ด)** ใช้บรรยายลักษณะภายนอกของหมวกเห็ด

- cap-shape (รูปร่างของหมวกเห็ด)
- cap-surface (ลักษณะพื้นผิวหมวกเห็ด)
- cap-color (สีของหมวกเห็ด)

**3. Other Characteristics (ลักษณะเฉพาะของเห็ด)**

- bruises (การเกิดรอยช้ำของเห็ด)
- odor (กลิ่นของเห็ด)
- spore-print-color (สีของผงสปอร์)

**4. Gill Characteristics (ลักษณะของครีบเห็ด)** ครีบเห็ดเป็นโครงสร้างบาง ๆ เรียงชิดติดกันเป็นแถว มักจะพบปรากฏอยู่ใต้หมวดเห็ด

- gill-attachment (ลักษณะการติดของครีบกับก้าน)
- gill-spacing (ระยะห่างของครีบ)
- gill-size (ขนาดของครีบ)
- gill-color (สีของครีบ)

**5. Stalk Structure (โครงสร้างของก้านเห็ด)** ลักษณะทางกายภาพของก้านเห็ด

- stalk-shape (รูปร่างของก้านเห็ด)
- stalk-root (ลักษณะรากของก้านเห็ด)

**6. Stalk Surface (พื้นผิวก้านเห็ด)** พื้นผิวของก้านเห็ดในตำแหน่งต่าง ๆ

- stalk-surface-above-ring (พื้นผิวก้านเหนือวงแหวน)
- stalk-surface-below-ring (พื้นผิวก้านใต้วงแหวน)

**7. Stalk Color (สีก้านเห็ด)** สีของก้านเห็ดในตำแหน่งต่าง ๆ

- stalk-color-above-ring (สีก้านเหนือวงแหวน)
- stalk-color-below-ring (สีก้านใต้วงแหวน)

**8. Veil Characteristics (ลักษณะของเยื่อหุ้มเห็ด)** คุณลักษณะของเยื่อหุ้มที่คลุมส่วนของเห็ด

- veil-type (ประเภทของเยื่อหุ้ม)
- veil-color (สีของเยื่อหุ้ม)

**9. Ring Characteristics (ลักษณะของวงแหวน)** ลักษณะของวงแหวนบนก้านเห็ด

- ring-number (จำนวนวงแหวน)
- ring-type (ประเภทของวงแหวน)

**10. Environmental Characteristics** ลักษณะของสภาพแวดล้อมที่พบเห็ด

- population (ความหนาแน่นของเห็ดในพื้นที่)
- habitat (สภาพแวดล้อมที่พบเห็ด)

โดยรายละเอียดของค่าตัวแปรทั้งหมดของแต่ละคุณลักษณะสามารถดูเพิ่มเติมได้ในตารางคำอธิบายคุณลักษณะของชุดข้อมูลใน *ภาคผนวก*

**หลักการและขั้นตอนการสกัด การเลือก และการเตรียมลักษณะ**

**1. การเตรียมข้อมูล (Data Preparation)**

ในการเตรียมหรือการทำความสะอาดข้อมูลก่อนนำไปคัดเลือกลักษณะเบื้องต้น ได้มีการตรวจสอบค่าของข้อมูลในแต่ละคอลัมน์เพื่อจัดการกับค่า Missing value จากชุดข้อมูลพบว่าในส่วนคอลัมน์ stalk-root (รากของต้นเห็ด) มีค่า '?' หมายถึงแทนค่าที่หายไปอยู่ จึงได้ทำการแทนที่ด้วย 'u' (unknown) เนื่องจากค่าที่หายไปมีจำนวน 2,480 คอลัมน์ซึ่งถือว่าเป็นข้อมูลจำนวนมาก จากนั้นได้มีการตรวจสอบหาข้อมูลค่าซ้ำ (Duplicated data) แล้วพบว่าไม่มีข้อมูลซ้ำซ้อนอยู่ภายในชุดข้อมูล

```
# แสดงจำนวนลักษณะของค่าที่มีในคอลัมน์ stalk-root
print(df['stalk-root'].value_counts())

# จัดการ Missing Value ด้วยการแทนที่ 'u' ลงไปในค่า '?'
df['stalk-root'] = df['stalk-root'].replace('?', 'u')
print("------ Check to find '?' ------\n", (df == '?').sum())
```

```
stalk-root
b    3776
?    2480
e    1120
c     556
r     192
Name: count, dtype: int64
------ Check to find '?' ------
 class                     0
cap-shape                  0
cap-surface                0
cap-color                  0
bruises                    0
odor                       0
gill-attachment            0
gill-spacing               0
gill-size                  0
gill-color                 0
stalk-shape                0
stalk-root                 0
stalk-surface-above-ring   0
stalk-surface-below-ring   0
```

ต่อมาเมื่อพิจารณาค่าของแต่ของละคอลัมน์พบว่าคอลัมน์ veil-type (ประเภทของเยื่อหุ้มเห็ด) มีลักษณะค่าเพียงอย่างเดียวคือ 'p' (partial (เยื่อหุ้มบางส่วน)) ซึ่งถือว่าเป็นคอลัมน์ที่มีค่าเดียว (constant feature) ที่เราสามารถทำการลบเพื่อลดคุณลักษณะ (Feature Reduction) และปรับปรุงประสิทธิภาพของโมเดลได้ ทำให้เหลือคอลัมน์ทั้งหมด 22 คอลัมน์

```
# ตรวจสอบคอลัมน์ veil-type
print(df['veil-type'].value_counts())

# ลบคอลัมน์ veil-tape ที่มีค่าเดียว (Constant value)
df.drop('veil-type', axis=1, inplace=True)
print("--- หลังจากการลบคอลัมน์ ---")
print("columns = ", df.shape[1])
```

```
veil-type
p    8124
Name: count, dtype: int64
--- หลังจากการลบคอลัมน์ ---
columns =  22
```

ในการเข้ารหัสข้อมูล (Data Encoding) ได้เลือกใช้วิธีการทำ Label Encoding แปลงข้อมูลให้อยู่ในรูปแบบเชิงตัวเลขก่อนนำไปใช้ในการฝึกแบบจำลอง Machine Learning เนื่องจากข้อมูลอยู่ในรูปแบบเชิงหมวดหมู่และมีค่าคุณลักษณะในแต่ละคอลัมน์จำนวนมากอยู่แล้ว โดยจะมีการใช้โมเดล Random Forest ที่เป็นโมเดลรูปแบบต้นไม้มาช่วยในการหาค่าตัวแปรคุณลักษณะที่สำคัญต่อไป

```python
# Label Encoding (แปลงตัวอักษรเป็นตัวเลขเพื่อเข้าโมเดล)
# แยกคอลัมน์ x (feature) และ y (target)
X = df.drop('class', axis=1)
y = df['class']

# Encoding y และ x
le = LabelEncoder()
y = le.fit_transform(y)

for col in X.columns:
    X[col] = LabelEncoder().fit_transform(X[col])
```

```python
print("ผลลัพธ์ 3 แถวแรกของคอลัมน์คุณลักษณะ:\n", X.head(3))
print("ผลลัพธ์ 3 แถวแรกของ y (class):\n", y[:3]) # poisonous = 0, edible = 1
```

```
ผลลัพธ์ 3 แถวแรกของคอลัมน์คุณลักษณะ:
   cap-shape  cap-surface  cap-color  bruises  odor  gill-attachment  \
0          5            2          4        1     6                1
1          5            2          9        1     0                1
2          0            2          8        1     3                1

   gill-spacing  gill-size  gill-color  stalk-shape  ...  \
0             0          1           4            0  ...
1             0          0           4            0  ...
2             0          0           5            0  ...

   stalk-surface-above-ring  stalk-surface-below-ring  stalk-color-above-ring  \
0                         2                         2                       7
1                         2                         2                       7
2                         2                         2                       7

   stalk-color-below-ring  veil-color  ring-number  ring-type  \
0                       7           2            1          4
1                       7           2            1          4
2                       7           2            1          4

   spore-print-color  population  habitat
0                  2           3        5
1                  3           2        1
2                  3           2        3

[3 rows x 21 columns]
ผลลัพธ์ 3 แถวแรกของ y (class):
 [1 0 0]
```

## 2. การวิเคราะห์คุณลักษณะที่สำคัญ (Feature Importance)

จากการวิเคราะห์คุณลักษณะที่สำคัญ (Feature Importance) สามารถช่วยให้เห็นว่าคุณลักษณะใดในชุดข้อมูลมีความสัมพันธ์ต่อการจำแนกว่าเห็ดแต่ละชนิดเป็นเห็ดที่มีพิษหรือไม่ โดยค่าความสำคัญ (Importance) ใช้เป็นตัวบ่งชี้ว่าการเปลี่ยนแปลงของค่าคุณลักษณะแต่ละตัวส่งผลต่อความสามารถในการทำนายของโมเดลมากน้อยเพียงใด

ในขั้นตอนการวิเคราะห์ ได้ทำการฝึกโมเดล **Random Forest** เพื่อใช้ในการทำนายชนิดของเห็ดและประเมินประสิทธิภาพของโมเดลเบื้องต้น จากนั้นจึงใช้เทคนิค **Permutation Importance** โดยการสุ่มสลับ

ค่าของคุณลักษณะแต่ละตัวในข้อมูล แล้วให้โมเดลทำการทำนายใหม่อีกครั้ง เพื่อตรวจสอบว่าประสิทธิภาพของโมเดลลดลงมากเพียงใด หากการสลับค่าของคุณลักษณะใดทำให้ประสิทธิภาพของโมเดลลดลงอย่างชัดเจน แสดงว่าคุณลักษณะนั้นมีความสำคัญต่อการทำนายของโมเดลเป็นอย่างมาก

```
--- ลำดับความสำคัญของคุณลักษณะทั้งหมด (Feature Importance Ranking) ---
 rank                  feature  original_column_no  importance  std_dev
    1                     odor                   5    0.006955 0.000668
    2                 gill-size                   8    0.002827 0.000304
    3        spore-print-color                  19    0.001083 0.000245
    4                cap-shape                   1    0.000000 0.000000
    5              cap-surface                   2    0.000000 0.000000
    6                  bruises                   4    0.000000 0.000000
    7                cap-color                   3    0.000000 0.000000
    8             gill-spacing                   7    0.000000 0.000000
    9          gill-attachment                   6    0.000000 0.000000
   10              stalk-shape                  10    0.000000 0.000000
   11               stalk-root                  11    0.000000 0.000000
   12 stalk-surface-above-ring                  12    0.000000 0.000000
   13               gill-color                   9    0.000000 0.000000
   14 stalk-surface-below-ring                  13    0.000000 0.000000
   15   stalk-color-above-ring                  14    0.000000 0.000000
   16               veil-color                  16    0.000000 0.000000
   17   stalk-color-below-ring                  15    0.000000 0.000000
   18              ring-number                  17    0.000000 0.000000
   19                ring-type                  18    0.000000 0.000000
   20               population                  20    0.000000 0.000000
   21                  habitat                  21    0.000000 0.000000

--- ผลลัพธ์ Top 3 Features ---
Rank 1: odor (คอลัมน์เดิมลำดับที่ 5) (Score: 0.006955)
Rank 2: gill-size (คอลัมน์เดิมลำดับที่ 8) (Score: 0.002827)
Rank 3: spore-print-color (คอลัมน์เดิมลำดับที่ 19) (Score: 0.001083)
```

จากผลการวิเคราะห์พบว่ามีคุณลักษณะที่มีค่าความสำคัญสูงอย่างเห็นได้ชัดอยู่ 3 ลักษณะ ได้แก่

**1. odor (กลิ่น), score: 0.006955**

กลิ่นของเห็ดเป็นตัวบ่งชี้ที่สำคัญต่อการจำแนกชนิดของเห็ด โดยเห็ดที่มีกลิ่น **Foul (เหม็นเน่า)** หรือ **Pungent (ฉุน)** มักปรากฏว่าเป็นเห็ดพิษ ในขณะที่เห็ดที่สามารถรับประทานได้มักไม่มีกลิ่นหรือมีกลิ่นเฉพาะตัวที่ไม่รุนแรง

**2. gill-size (ขนาดครีบ), score: 0.002827**

ขนาดของครีบเห็ดเป็นอีกหนึ่งคุณลักษณะที่ช่วยในการจำแนกชนิดของเห็ด ในชุดข้อมูลนี้พบว่าเห็ดที่มีลักษณะครีบ **แคบ (Narrow)** มักมีแนวโน้มที่จะเป็นเห็ดพิษ

**3. spore-print-color (สีของสปอร์), score: 0.001083**

สีของสปอร์สามารถช่วยระบุชนิดของเห็ดได้อย่างแม่นยำ เนื่องจากสีของสปอร์เป็นลักษณะที่ค่อนข้างคงที่ตามพันธุกรรม ในขณะที่สีของหมวกเห็ดอาจเปลี่ยนแปลงได้ตามสภาพแวดล้อมหรือสภาพอากาศ

### 3. การเลือกจำนวนคุณลักษณะที่เหมาะสม (Feature Selection)

หลังจากทำการวิเคราะห์ความสำคัญของคุณลักษณะ (Feature Importance) แล้ว ขั้นตอนถัดไปคือการคัดเลือกคุณลักษณะที่เหมาะสมสำหรับการสร้างโมเดล โดยใช้เทคนิค **Recursive Feature Elimination (RFE)** ร่วมกับโมเดล Random Forest

เทคนิค RFE เป็นวิธีการคัดเลือกคุณลักษณะที่ทำงานโดยการฝึกโมเดลกับชุดข้อมูล จากนั้นทำการประเมินความสำคัญของคุณลักษณะแต่ละตัว และทำการตัดคุณลักษณะที่มีความสำคัญต่ำออกทีละขั้นตอนจนกระทั่งเหลือจำนวนคุณลักษณะที่ต้องการ วิธีนี้ช่วยให้สามารถเลือกชุดคุณลักษณะที่มีประสิทธิภาพสูงสุดสำหรับการทำนายได้ โดยในโครงงานนี้ได้มีการใช้ Random Forest Classifier เป็นตัวประเมินความสำคัญของคุณลักษณะ และกำหนดให้ RFE คัดเลือกคุณลักษณะที่ดีที่สุดจำนวน 3 ตัวแปร เนื่องจากจากผลการวิเคราะห์ Permutation Importance ก่อนหน้า พบว่ามีเพียง 3 คุณลักษณะที่มีค่าความสำคัญมากกว่า 0 อย่างมีนัยสำคัญ จึงกำหนดให้เป็นจำนวนคุณลักษณะที่เหมาะสมสำหรับการสร้างโมเดล

หลังจากดำเนินการ Feature Selection แล้วจึงได้มีการสร้างชุดข้อมูลใหม่ที่ประกอบด้วยเฉพาะคุณลักษณะที่ถูกคัดเลือกเพื่อนำไปใช้ในการฝึกโมเดลในขั้นตอนต่อไป

```python
# 1. กำหนด Estimator (ใช้ Random Forest)
rf = RandomForestClassifier(n_estimators=200, random_state=42)

# 2. ใช้ RFE เพื่อคัดเลือกฟีเจอร์ที่ดีที่สุด 3 อันดับ
# (จากที่รันมีแค่ 3 ฟีเจอร์ที่มีค่า importance และ std_dev)
selector = RFE(rf, n_features_to_select=3, step=1)
selector.fit(X, y)

# 3. สกัดรายชื่อฟีเจอร์ที่ถูกเลือกออกมา
selected_features = X.columns[selector.support_]

print(f"------ ผลการทำ Feature Selection ------")
print(f"จำนวนคุณลักษณะที่เลือก: {len(selected_features)}")
print(f"คุณลักษณะที่เหลืออยู่: {list(selected_features)}")

# 4. สร้าง Dataset ใหม่ที่มีเฉพาะฟีเจอร์ที่ถูกเลือก
X_selected = X[selected_features]
```

```
------ ผลการทำ Feature Selection ------
จำนวนคุณลักษณะที่เลือก: 3
คุณลักษณะที่เหลืออยู่: ['odor', 'gill-color', 'spore-print-color']
```

จากการวิเคราะห์ด้วยเทคนิค Permutation Importance พบว่าคุณลักษณะอื่น ๆ ในชุดข้อมูล เช่น cap-shape, bruises และ habitat มีค่าความสำคัญใกล้เคียงกับศูนย์ ซึ่งแสดงว่าคุณลักษณะเหล่านี้ไม่ได้ช่วยเพิ่มประสิทธิภาพของโมเดลอย่างมีนัยสำคัญในการทำนายชนิดของเห็ด ดังนั้น การเลือกใช้เพียง 3 คุณลักษณะหลักที่ปรากฏค่ามากกว่าศูนย์ ได้แก่ odor, gill-size และ spore-print-color สามารถช่วยลดจำนวนตัวแปรที่ไม่จำเป็นในโมเดล ทำให้โมเดลมีความซับซ้อนลดลง (Reduced Model Complexity) อีกทั้งยังช่วยลดโอกาสเกิดปัญหา Overfitting และทำให้โมเดลสามารถประมวลผลได้รวดเร็วและมีประสิทธิภาพมากขึ้น

## 4. การแบ่งชุดข้อมูล (Data Splitting)

ใช้เฉพาะคุณลักษณะที่ผ่านการคัดเลือกจากขั้นตอน Feature Selection ได้แก่ odor, gill-size และ spore-print-color เพื่อสร้างชุดข้อมูลสำหรับฝึกโมเดล

```python
# 1. เลือกเฉพาะคุณลักษณะที่ผ่านการคัดเลือก (Top 3)
selected_features = ['odor', 'gill-size', 'spore-print-color']
X_final = X[selected_features]
y_final = y  # คลาสเป้าหมาย (Edible/Poisonous)

# 2. แบ่งข้อมูลเป็น 80% (Train/CV) และ 20% (Evaluation)
# stratify=y ช่วยให้สัดส่วนของเห็ดพิษและเห็ดกินได้ในทั้งสองชุดมีความสมดุลกัน
X_train_cv, X_eval, y_train_cv, y_eval = train_test_split(
    X_final,
    y_final,
    test_size=0.20,
    random_state=42,
    stratify=y_final
)

print(f"------ สรุปการจัดเตรียมข้อมูล ------")
print(f"จำนวนข้อมูลทั้งหมด: {len(df)} แถว")
print(f"ชุดสร้างแบบจำลองและทวนสอบ (80%): {X_train_cv.shape[0]} แถว")
print(f"ชุดทดสอบประสิทธิภาพสุดท้าย (20%): {X_eval.shape[0]} แถว")
```

```
------ สรุปการจัดเตรียมข้อมูล ------
จำนวนข้อมูลทั้งหมด: 8124 แถว
ชุดสร้างแบบจำลองและทวนสอบ (80%): 6499 แถว
ชุดทดสอบประสิทธิภาพสุดท้าย (20%): 1625 แถว
```

ในส่วนนี้ใช้การแบ่งข้อมูลแบบ 80:20 เพื่อแยกระหว่างกระบวนการเรียนรู้ของโมเดลและการประเมินประสิทธิภาพของโมเดลอย่างชัดเจน ชุดข้อมูลทั้งหมดจำนวน 8,124 แถว ถูกแบ่งออกเป็นสองส่วน ได้แก่

- **ชุดสร้างแบบจำลองและทวนสอบ (Training and Cross-Validation Set: 80%)**
  มีจำนวน 6,499 แถว ใช้สำหรับฝึกโมเดลและใช้ในกระบวนการปรับแต่งพารามิเตอร์ของโมเดล
- **ชุดทดสอบประสิทธิภาพ (Evaluation Set: 20%)**
  มีจำนวน 1,625 แถว ถูกแยกเก็บไว้เพื่อใช้ประเมินประสิทธิภาพของโมเดลหลังจากผ่านการฝึกแล้ว โดยชุดข้อมูลนี้ทำหน้าที่เป็นตัวแทนของข้อมูลใหม่ที่โมเดลไม่เคยเห็นมาก่อน

การแบ่งข้อมูลได้ใช้เทคนิค Stratified Sampling โดยกำหนดพารามิเตอร์ stratify เพื่อรักษาสัดส่วนของเห็ดที่รับประทานได้และมีพิษให้ใกล้เคียงกันในทั้งสองชุดข้อมูล ช่วยลดความเอนเอียงของข้อมูลและทำให้การประเมินผลมีความน่าเชื่อถือมากขึ้น

**เทคนิคที่ใช้ในการพัฒนาแบบจำลอง**

**1. กระบวนการทวนสอบไขว้ (k-Fold Cross Validation)**

การใช้เทคนิค k-Fold Cross Validation ภายในชุดข้อมูล Training and Cross-Validation Set (80%) สามารถเพิ่มความน่าเชื่อถือในการประเมินประสิทธิภาพของโมเดล โดยในที่นี้เลือกใช้เทคนิค 5-Fold Cross Validation ที่เป็นการแบ่งข้อมูลให้มีขนาดใกล้เคียงกันออกเป็น 5 ส่วน ในแต่ละรอบของการฝึกโมเดลจะใช้ข้อมูล 4 ส่วนสำหรับการเรียนรู้ (Training) และใช้ 1 ส่วนสำหรับการตรวจสอบผล (Validation) จากนั้นจะสลับชุดข้อมูลสำหรับการตรวจสอบไปเรื่อย ๆ จนครบทั้ง 5 รอบ

ผลลัพธ์ที่ได้จากแต่ละรอบจะถูกนำมาคำนวณค่าเฉลี่ยของประสิทธิภาพ เช่น ค่าความแม่นยำ (Accuracy) เพื่อใช้เป็นตัวแทนของประสิทธิภาพโดยรวมของโมเดล วิธีนี้จะช่วยลดความเอนเอียงที่อาจเกิดจากการแบ่งข้อมูลเพียงครั้งเดียวและส่งผลให้การประเมินผลมีความน่าเชื่อถือมากขึ้น นอกจากนี้เทคนิค Cross Validation ยังถูกใช้ร่วมกับ Grid Search เพื่อค้นหาค่า Hyperparameters ที่เหมาะสมที่สุดสำหรับแต่ละโมเดล

**2. การป้องกันปัญหาการเข้ากันมากเกินไป (Overfitting)**

ปัญหาการเข้ากันมากเกินไปหรือ Overfitting เกิดขึ้นเมื่อโมเดลสามารถเรียนรู้ข้อมูลในชุดฝึกสอนได้ดีมากเกินไปจนไม่สามารถทำนายข้อมูลใหม่ได้อย่างมีประสิทธิภาพ เพื่อลดความเสี่ยงของการเกิด Overfitting จึงได้มีการใช้เทคนิควิธีต่าง ๆ ได้แก่

1. **Feature Selection** การเลือกใช้เฉพาะคุณลักษณะที่มีความสำคัญสูงจำนวน 3 ตัวแปร (odor, gill-size, spore-print-color) ช่วยลดจำนวนตัวแปรที่ไม่จำเป็น และลดความซับซ้อนของโมเดล
2. **Cross Validation** การใช้ 5-Fold Cross Validation ช่วยให้การประเมินโมเดลเกิดขึ้นกับหลายชุดข้อมูลย่อย ทำให้ผลการประเมินมีความเสถียรและลดโอกาสที่โมเดลจะเหมาะกับข้อมูลเพียงบางส่วน
3. **Evaluation Set** การเก็บชุดข้อมูล 20% ไว้สำหรับการทดสอบขั้นสุดท้ายช่วยให้สามารถตรวจสอบได้ว่าโมเดลยังคงมีประสิทธิภาพที่ดีเมื่อทดสอบกับข้อมูลที่ไม่เคยใช้ในการฝึก

ด้วยวิธีการดังกล่าวโมเดลที่พัฒนาขึ้นจึงมีความสามารถในการทั่วไปกับข้อมูลใหม่ (Generalization) ได้ดีขึ้นและลดโอกาสเกิด Overfitting

**แบบจำลองการจำแนกประเภท**

**1. K-Nearest Neighbors algorithm (kNN)**

แบบจำลอง k-Nearest Neighbors (kNN) ใช้หลักการของอัลกอริทึม kNN คือการพิจารณาความคล้ายคลึงของข้อมูลใหม่กับข้อมูลที่มีอยู่ในฐานข้อมูล เมื่อมีข้อมูลเห็ดตัวอย่างใหม่เข้ามาระบบจะคำนวณระยะห่าง (Distance) ระหว่างข้อมูลใหม่นั้นกับข้อมูลเห็ดทั้งหมดในชุดข้อมูลฝึกสอน จากนั้นจะเลือกข้อมูลที่มีระยะใกล้ที่สุดจำนวน k ตัวอย่าง และพิจารณาว่าข้อมูลส่วนใหญ่ในกลุ่มเพื่อนบ้านเหล่านั้นอยู่ในประเภทใด ข้อมูลใหม่ก็จะถูกจัดให้อยู่ในประเภทนั้น

เพื่อเพิ่มประสิทธิภาพของแบบจำลอง kNN ได้มีการใช้เทคนิค Grid Search ร่วมกับ 5-Fold Cross Validation บนชุดข้อมูลฝึกสอน 80% เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล พารามิเตอร์ที่นำมาทดลองปรับแต่ง คือ

- **n_neighbors (k)** จำนวนเพื่อนบ้านที่ใช้ในการตัดสินใจ
- **weights** วิธีการให้น้ำหนักกับเพื่อนบ้าน
- **metric** วิธีการคำนวณระยะห่างระหว่างข้อมูล

```
Best Parameters: {'metric': 'euclidean', 'n_neighbors': 3, 'weights': 'uniform'}
Best Cross-Validation Accuracy: 0.9948

--- Evaluation on Unseen Data (20%) ---
Final Accuracy: 0.9926
              precision    recall  f1-score   support

           0       0.99      1.00      0.99       842
           1       1.00      0.98      0.99       783

    accuracy                           0.99      1625
   macro avg       0.99      0.99      0.99      1625
weighted avg       0.99      0.99      0.99      1625
```

จากการทดลองพบว่าชุดค่าพารามิเตอร์ที่ให้ผลลัพธ์ดีที่สุด ได้แก่

- **metric** = Euclidean
- **n_neighbors (k)** = 3
- **weights** = uniform
- **ค่าความแม่นยำเฉลี่ยจากกระบวนการ 5-Fold Cross Validation = 0.9948 (99.48%)**

หลังจากได้ชุดค่าพารามิเตอร์ที่ดีที่สุดแล้ว ได้นำแบบจำลองที่ได้ไปทดสอบกับ Evaluation Set 20% ที่ถูกแยกออกมาและไม่เคยถูกใช้ในการฝึกโมเดลมาก่อน ผลการประเมินประสิทธิภาพของโมเดลพบว่า

- **Accuracy บน Cross-Validation Set** 0.9948 (99.48%)
- **Accuracy บน Evaluation Set** 0.9926 (99.26%)

ค่าความแตกต่างระหว่างสองชุดข้อมูล (Delta) มีค่าเพียง **0.0022 (0.22%)** แสดงให้เห็นว่าแบบจำลองสามารถเรียนรู้รูปแบบของข้อมูลได้ดี และมีความสามารถในการนำไปใช้กับข้อมูลใหม่ได้อย่างมีประสิทธิภาพ และไม่เกิดปัญหา Overfitting

ผลลัพธ์จาก Evaluation Set จำนวน 1,625 ตัวอย่าง พบว่าแบบจำลองมีประสิทธิภาพในการจำแนกเห็ดทั้งสองประเภทได้ดี ผลลัพธ์ของการการจำแนกเห็ดพิษ (Class 1) เป็นดังต่อไปนี้

- **Precision = 1.00 (100%)**
  หากโมเดลระบุผลการทำนายว่าเป็นเห็ดพิษ ผลดังกล่าวจะถูกต้องเสมอโดยไม่เกิดการทำนายผิดว่าเป็นเห็ดพิษในกรณีที่จริงแล้วไม่ใช่ (False positive)
- **Recall = 0.98 (98%)**
  แสดงว่าโมเดลสามารถตรวจจับเห็ดพิษที่มีอยู่ในข้อมูลได้เกือบทั้งหมด
- **F1-Score = 0.99**
  แสดงถึงความสมดุลระหว่างค่า Precision และ Recall

โดยรวมแล้วแบบจำลอง kNN สามารถจำแนกประเภทของเห็ดได้อย่างแม่นยำและมีความสมดุลในการทำนายทั้งเห็ดที่รับประทานได้และเห็ดพิษ

**2. XGBoost Classifier**

XGBoost (Extreme Gradient Boosting) เป็นอัลกอริทึมประเภท Ensemble Learning ที่พัฒนาต่อยอดจาก Gradient Boosting โดยใช้แนวคิดการสร้าง Decision Tree ขนาดเล็กหลายต้นต่อเนื่องกัน ทำให้สามารถเรียนรู้รูปแบบข้อมูลที่ซับซ้อนได้อย่างมีประสิทธิภาพ เช่นเดียวกับโมเดลก่อนหน้า โมเดลนี้ได้มีการปรับค่าพารามิเตอร์ของโมเดลด้วยวิธี Grid Search ร่วมกับ 5-Fold Cross Validation บนชุดข้อมูล Training (80%) เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดโดยกำหนดช่วงค่าที่ทดลองดังนี้

- **n_estimators** จำนวนต้นไม้ที่ใช้ในโมเดล
- **max_depth** ความลึกของต้นไม้แต่ละต้น
- **learning_rate** อัตราการเรียนรู้ของโมเดล

```
Best Parameters (XGBoost): {'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50}
Best CV Accuracy: 0.9945

Final Evaluation Accuracy (XGBoost): 0.9926
              precision    recall  f1-score   support

           0       0.99      1.00      0.99       842
           1       1.00      0.98      0.99       783

    accuracy                           0.99      1625
   macro avg       0.99      0.99      0.99      1625
weighted avg       0.99      0.99      0.99      1625
```

ผลการค้นหาพารามิเตอร์ที่ดีที่สุด พบว่า

- **learning_rate** = 0.1
- **max_depth** = 3
- **n_estimators** = 50

โครงสร้างดังกล่าวแสดงให้เห็นว่าโมเดลเลือกใช้ ต้นไม้ที่มีความลึกเพียง 3 ชั้น และจำนวนต้นไม้ 50 ต้น ซึ่งเป็นโครงสร้างที่ค่อนข้างเรียบง่าย แต่สามารถให้ประสิทธิภาพสูงและช่วยลดความเสี่ยงของปัญหา Overfitting

ผลการประเมินความแม่นยำของโมเดล

- **Accuracy บน Cross-Validation Set** 0.9945 (99.45%)
- **Accuracy บน Evaluation Set** 0.9926 (99.26%)

ความแตกต่างของค่าความแม่นยำเท่ากับ **0.0019 หรือ 0.19%** ซึ่งถือว่ามีค่าน้อยมาก แสดงให้เห็นว่าโมเดลมีความสามารถในการ Generalize กับข้อมูลที่ไม่เคยเห็นมาก่อนได้ดีและไม่เกิดปัญหา Overfitting

การวิเคราะห์ผลลัพธ์เชิงลึกบนชุดข้อมูล Evaluation จำนวน 1,625 ตัวอย่าง พบว่า

- **Precision (Class 1 / เห็ดพิษ) = 1.00**

  โมเดลไม่ทำนายเห็ดที่ปลอดภัยว่าเป็นเห็ดพิษผิดพลาดเลย
- **Recall (Class 1 / เห็ดพิษ) = 0.98**

  โมเดลสามารถตรวจจับเห็ดพิษได้เกือบทั้งหมด
- **F1-Score = 0.99**

  แสดงถึงความสมดุลระหว่าง Precision และ Recall

ผลลัพธ์ดังกล่าวแสดงให้เห็นว่า XGBoost สามารถจำแนกประเภทเห็ดได้อย่างแม่นยำและมีเสถียรภาพสูง

**3. เครือข่ายประสาท (Neural Network)**

Neural Network หรือ Multilayer Perceptron (MLP) เป็นโมเดลที่เลียนแบบการทำงานของระบบประสาท ข้อมูลจะถูกส่งผ่านชั้นซ่อน (Hidden Layer) เพื่อเรียนรู้ความสัมพันธ์ที่ซับซ้อนระหว่างคุณลักษณะของข้อมูล ในการสร้างโมเดลนี้ใช้เครือข่ายประสาทเทียมที่มี Hidden Layer จำนวน 1 ชั้น และทำการปรับค่าพารามิเตอร์ด้วย Grid Search ร่วมกับ 5-Fold Cross Validation เช่นเดียวกับโมเดลก่อนหน้า การทดลองปรับค่าพารามิเตอร์สำคัญ ได้แก่

- **hidden_layer_sizes** โครงสร้างของชั้นซ่อน
- **activation** ฟังก์ชันกระตุ้นของเซลล์ประสาท
- **alpha** ค่าการทำ Regularization เพื่อป้องกัน Overfitting
- **learning_rate** รูปแบบการปรับค่า Learning Rate

```
Best Parameters (Neural Network): {'activation': 'tanh', 'alpha': 0.05, 'hidden_layer_sizes': (50,), 'learning_rate': 'constant'}
Best CV Accuracy: 0.9945

Final Evaluation Accuracy (Neural Network): 0.9926
              precision    recall  f1-score   support

           0       0.99      1.00      0.99       842
           1       1.00      0.98      0.99       783

    accuracy                           0.99      1625
   macro avg       0.99      0.99      0.99      1625
weighted avg       0.99      0.99      0.99      1625
```

ผลการค้นหาพารามิเตอร์ที่เหมาะสมที่สุด คือ

- **activation** = tanh
- **hidden_layer_sizes** = (50,)
- **alpha** = 0.05
- **learning_rate** = constant

โครงสร้างที่ได้หมายถึงการใช้ Hidden Layer จำนวน 1 ชั้นที่มี 50 โหนด พร้อมฟังก์ชันกระตุ้นแบบ tanh ซึ่งช่วยให้โมเดลสามารถเรียนรู้รูปแบบข้อมูลที่มีความสัมพันธ์ไม่เป็นเชิงเส้นได้ ผลการประเมินความแม่นยำของ Neural Network พบว่า

- **Accuracy บน Cross-Validation Set** 0.9948 (99.48%)
- **Accuracy บน Evaluation Set** 0.9926 (99.26%)

ความแตกต่างของค่าความแม่นยำเท่ากับ **0.0019 หรือ 0.19%** ซึ่งบ่งชี้ว่าโมเดลมีความเสถียรและสามารถนำไปใช้กับข้อมูลใหม่ได้ดี

จากผลการจำแนกข้อมูลพบว่าโมเดลมีประสิทธิภาพสูงในทุกตัวชี้วัดเช่นเดียวกับโมเดลก่อนหน้า

- **Precision (เห็ดพิษ) = 1.00**
- **Recall (เห็ดพิษ) = 0.98**
- **F1-Score = 0.99**

แสดงให้เห็นว่า Neural Network สามารถจำแนกเห็ดที่ได้อย่างสมดุลและมีความแม่นยำสูงเช่นกัน

**4. การทำ Grid search เพื่อหา Best Parameter Set (Hyperparameter)**

เพื่อให้แบบจำลองแต่ละอัลกอริทึมมีประสิทธิภาพสูงสุดในการจำแนกประเภทเห็ด การศึกษานี้ได้ใช้วิธี Grid Search ร่วมกับ 5-Fold Cross Validation บนชุดข้อมูลฝึกสอน (Training Set) ซึ่งมีสัดส่วนร้อยละ 80 ของข้อมูลทั้งหมด เพื่อค้นหาชุดค่าพารามิเตอร์ (Hyperparameters) ที่เหมาะสมที่สุดสำหรับแต่ละโมเดล ผลการค้นหาค่าพารามิเตอร์ที่ดีที่สุดของแต่ละอัลกอริทึมแสดงดังตารางต่อไปนี้

| Algorithm | Best Parameters | Best CV Score |
|---|---|---|
| **k-Nearest Neighbors (kNN)** | metric = euclidean, n_neighbors = 3, weights = uniform | 0.994769 |
| **XGBoost** | learning_rate = 0.1, max_depth = 3, n_estimators = 50 | 0.994461 |
| **Neural Network** | activation = tanh, alpha = 0.05, hidden_layer_sizes = (50,), learning_rate = constant | 0.994461 |

จากผลการทดลองพบว่าแบบจำลองทั้งสามประเภทให้ค่าความแม่นยำเฉลี่ยจากการทวนสอบไขว้ (Cross Validation) ที่ใกล้เคียงกันมาก โดยมีค่าประมาณ ร้อยละ 99.44 - 99.48 ซึ่งสะท้อนให้เห็นว่าคุณลักษณะที่ใช้ในการวิเคราะห์มีความสามารถในการจำแนกประเภทเห็ดได้อย่างมีประสิทธิภาพ

**การเปรียบเทียบจุดเด่นและข้อจำกัดของแต่ละแบบจำลอง**

สามารถสรุปจุดเด่นและข้อจำกัดของแบบจำลองแต่ละประเภทได้ดังนี้

k-Nearest Neighbors (kNN)

- **ข้อดี** โครงสร้างของโมเดลเรียบง่ายและเข้าใจได้ง่าย และไม่จำเป็นต้องทำการฝึกโมเดลล่วงหน้า (Lazy Learning)
- **ข้อจำกัด** ประสิทธิภาพในการทำนายอาจลดลงเมื่อขนาดข้อมูลเพิ่มขึ้นมาก และอาจต้องเก็บข้อมูลทั้งหมดไว้เพื่อใช้เปรียบเทียบระยะทาง

XGBoost

- **ข้อดี** สามารถเรียนรู้ความสัมพันธ์ของข้อมูลได้อย่างมีประสิทธิภาพ ให้ผลลัพธ์ที่มีความเสถียรสูง และมีความสามารถในการจัดการ Overfitting ได้ดี
- **ข้อจำกัด** การปรับค่าพารามิเตอร์อาจใช้เวลาในการคำนวณค่อนข้างมาก

Neural Network

- **ข้อดี** มีความสามารถในการเรียนรู้ความสัมพันธ์ที่ซับซ้อนของข้อมูลได้ดี และสามารถปรับขยายโครงสร้างเพื่อรองรับข้อมูลที่มีความซับซ้อนสูงได้
- **ข้อจำกัด** ต้องใช้ทรัพยากรในการประมวลผลมากกว่าอัลกอริทึมแบบดั้งเดิม และการตีความผลลัพธ์ของโมเดลทำได้ยากกว่าโมเดลประเภทอื่น

**ตารางเปรียบเทียบเชิงประยุกต์ใช้ของแบบจำลอง**

| เกณฑ์การเปรียบเทียบ | k-Nearest Neighbors (kNN) | XGBoost | Neural Network (MLP) |
|---|---|---|---|
| **ความเสถียรของโมเดล** | 0.22% | 0.19% | 0.19% |
| **ลักษณะการใช้ทรัพยากร** | ใช้หน่วยความจำสูง เนื่องจากต้องเก็บข้อมูลทั้งหมดไว้เพื่อคำนวณระยะทาง | ใช้ทรัพยากรค่อนข้างต่ำ หลังการฝึกโมเดลสามารถพยากรณ์ได้อย่างมีประสิทธิภาพ | ใช้ทรัพยากรประมวลผลสูงกว่า เนื่องจากต้องคำนวณผ่านโครงข่ายประสาทหลายชั้น |
| **ความเร็วในการพยากรณ์** | ค่อนข้างช้า เมื่อขนาดข้อมูลเพิ่มขึ้น | รวดเร็ว | รวดเร็ว |
| **ความเหมาะสมกับชุดข้อมูล** | เหมาะสม เนื่องจากข้อมูลมีการแบ่งกลุ่มที่ค่อนข้างชัดเจน | เหมาะสมและมีความเสถียรในการพยากรณ์ | สามารถใช้งานได้ แต่มีความซับซ้อนของโมเดลสูงเมื่อเทียบกับจำนวนคุณลักษณะของข้อมูล |

จากตารางเปรียบเทียบพบว่าแบบจำลองทั้งสามให้ประสิทธิภาพใกล้เคียงกัน อย่างไรก็ตาม XGBoost แสดงให้เห็นถึงความสมดุลระหว่างความแม่นยำ ความเสถียรของโมเดล และประสิทธิภาพในการประมวลผล จึงมีความเหมาะสมสำหรับการนำไปประยุกต์ใช้งานจริงมากที่สุด

**การประเมินประสิทธิภาพของแบบจำลอง**

เพื่อประเมินประสิทธิภาพของแบบจำลองและความสามารถในการนำไปใช้งานกับข้อมูลใหม่ (Generalization) จึงได้มีการเปรียบเทียบค่าความแม่นยำ (Accuracy) ที่ได้จากกระบวนการ 5-Fold Cross Validation บนชุดข้อมูลฝึกสอน (Training Set) และผลลัพธ์จากชุดข้อมูลทดสอบจริง (Evaluation Set) ที่กันไว้ร้อยละ 20 ของข้อมูลทั้งหมด นอกจากนี้ได้คำนวณ ค่าความต่าง (Delta) ระหว่างค่าความแม่นยำของทั้งสองชุดข้อมูล เพื่อใช้ตรวจสอบเสถียรภาพของแบบจำลองและวิเคราะห์แนวโน้มของปัญหา Overfitting โดยสามารถสรุปผลการทดลองได้ดังตารางต่อไปนี้

| **อัลกอริทึม (Algorithm)** | CV Accuracy (80%) | Evaluation Accuracy (20%) | Delta | **สถานะของแบบจำลอง** |
|---|---|---|---|---|
| **k-Nearest Neighbors (kNN)** | 0.9948 | 0.9926 | 0.0022 | Good Fit |
| **XGBoost** | 0.9945 | 0.9926 | 0.0019 | Good Fit |
| **Neural Network (MLP)** | 0.9945 | 0.9926 | 0.0019 | Good Fit |

จากการวิเคราะห์ค่าความแม่นยำและค่าความต่างของแบบจำลองทั้งสามประเภท สามารถสรุปประเด็นสำคัญได้ดังนี้

**1. การตรวจสอบปัญหา Underfitting**

แบบจำลองทุกประเภทให้ค่าความแม่นยำในขั้นตอน Cross Validation สูงกว่าร้อยละ 99 แสดงให้เห็นว่าแบบจำลองสามารถเรียนรู้รูปแบบและความสัมพันธ์ของข้อมูลได้อย่างเหมาะสม จึงไม่พบสัญญาณของปัญหา Underfitting ซึ่งเป็นกรณีที่โมเดลไม่สามารถเรียนรู้จากข้อมูลได้เพียงพอ

**2. การตรวจสอบปัญหา Overfitting**

การพิจารณาปัญหา Overfitting สามารถประเมินได้จากค่าความต่าง (Delta) ระหว่างค่าความแม่นยำของชุด Cross Validation และชุด Evaluation

ผลการทดลองพบว่าแบบจำลองทุกประเภทมีค่าความต่างต่ำมาก โดยมีค่าสูงสุดเพียง 0.0022 (0.22%) ซึ่งถือว่าอยู่ในระดับต่ำมาก และต่ำกว่าเกณฑ์ที่มักใช้พิจารณาปัญหา Overfitting (ประมาณ 1%)

ดังนั้นจึงสามารถสรุปได้ว่าแบบจำลองทั้งสามอยู่ในสภาวะ Good Fit กล่าวคือ โมเดลไม่ได้จดจำข้อมูลฝึกสอนมากเกินไป และสามารถนำความรู้ที่เรียนรู้ไปประยุกต์ใช้กับข้อมูลใหม่ได้อย่างเหมาะสม

**3. ความเสถียรของแบบจำลอง**

ค่าความแม่นยำของชุด Evaluation ที่เป็นข้อมูลที่แบบจำลองไม่เคยเห็นมาก่อน มีค่าใกล้เคียงกับผลลัพธ์จากชุด Cross Validation ในทุกอัลกอริทึม แสดงให้เห็นว่าแบบจำลองมี ความเสถียรในการพยากรณ์ (Model Stability) ภายใต้คุณลักษณะที่คัดเลือกมา ได้แก่ odor, gill-size และ spore-print-color โดยที่

ผลลัพธ์ดังกล่าวบ่งชี้ว่าคุณลักษณะทั้งสามสามารถอธิบายความแตกต่างระหว่างเห็ดที่รับประทานได้และเห็ดพิษได้อย่างมีประสิทธิภาพ และช่วยให้แบบจำลองสามารถนำไปใช้กับข้อมูลใหม่ได้อย่างน่าเชื่อถือ

**กราฟเปรียบเทียบประสิทธิภาพ (Performance Comparison Analysis)**

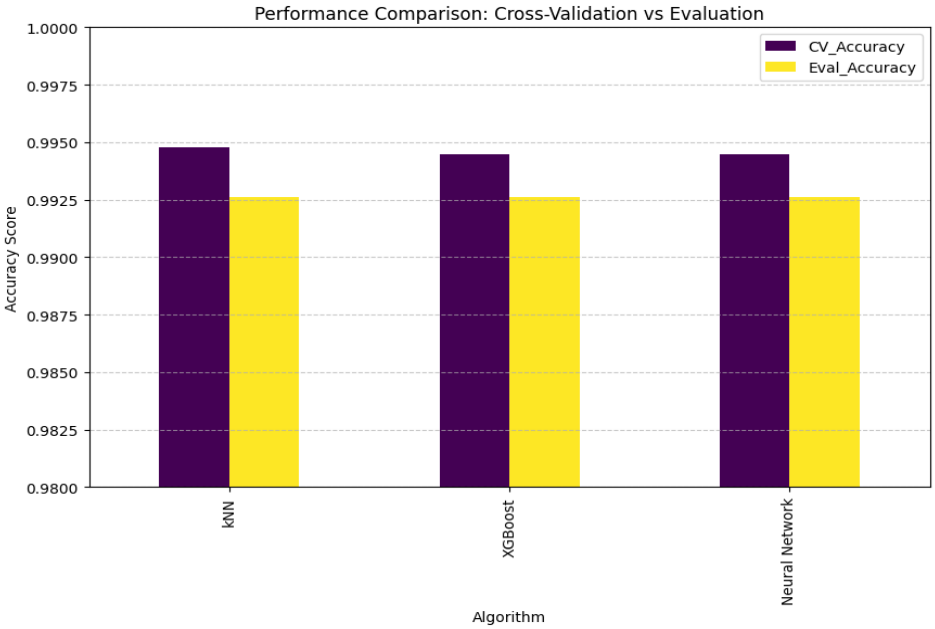


กราฟแท่งแสดงการเปรียบเทียบค่าความแม่นยำ (Accuracy) ระหว่างชุดข้อมูลทวนสอบแบบ 5-Fold Cross-Validation (CV) และชุดข้อมูลทดสอบจริง (Evaluation Set) สามารถวิเคราะห์ผลลัพธ์ที่สำคัญได้ดังนี้

- **การยืนยันสภาวะ Good Fit ของแบบจำลอง**

ค่าความแม่นยำจากทั้งสองชุดข้อมูลมีค่าใกล้เคียงกันมากในทุกโมเดล โดยมีค่าความแตกต่าง (Delta) อยู่ในช่วงเพียง 0.0018 - 0.0022 หรือประมาณ 0.18% - 0.22% ผลลัพธ์ดังกล่าวสะท้อนว่าแบบจำลองมีความสมดุลในการเรียนรู้ข้อมูล กล่าวคือ ไม่เกิดปัญหา Overfitting (การจดจำข้อมูลฝึกสอนมากเกินไป) หรือปัญหา Underfitting เนื่องจากแบบจำลองสามารถทำค่าความแม่นยำได้สูงกว่า 99% ตั้งแต่ขั้นตอนการฝึกสอน

- **ความสามารถในการนำไปใช้งานกับข้อมูลใหม่ (Generalization Ability)**

จากกราฟจะเห็นว่าแท่งกราฟของ Evaluation Accuracy มีความสูงใกล้เคียงกับแท่ง Cross-Validation Accuracy ในทุกโมเดล แสดงให้เห็นว่าแบบจำลองสามารถนำความรู้ที่เรียนรู้จากข้อมูลฝึกสอนไปใช้พยากรณ์ข้อมูลที่ไม่เคยเห็นมาก่อนได้อย่างมีประสิทธิภาพและเสถียร

- **การเปรียบเทียบระหว่างอัลกอริทึม**

แม้ว่าอัลกอริทึมทั้งสามจะให้ค่าความแม่นยำในระดับที่ใกล้เคียงกันมาก แต่เมื่อพิจารณาค่าความแตกต่างระหว่าง Cross-Validation และ Evaluation พบว่า XGBoost และ Neural Network มีค่า Delta ต่ำกว่าเล็กน้อย เมื่อเทียบกับ kNN ซึ่งสะท้อนถึงความเสถียรของโมเดลที่ดีกว่า

**ตารางสรุปผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง**

| Algorithm | CV Accuracy (80%) | Eval Accuracy (20%) | Precision (Poisonous) | Recall (Poisonous) | Delta |
|---|---|---|---|---|---|
| **XGBoost** | 0.9945 | 0.9926 | 1.00 | 0.98 | 0.0019 |
| **Neural Network** | 0.9945 | 0.9926 | 1.00 | 0.98 | 0.0019 |
| **kNN** | 0.9948 | 0.9926 | 1.00 | 0.98 | 0.0022 |

**การวิเคราะห์ตัวชี้วัดด้านความปลอดภัย (Precision & Recall)**

เมื่อพิจารณาค่าตัวชี้วัด Precision และ Recall สำหรับ เห็ดพิษ (Class 1) พบว่าแบบจำลองทั้งสามให้ผลลัพธ์ที่ใกล้เคียงกัน โดยมีประเด็นสำคัญดังนี้

- **Precision = 1.00 (100%)**

แบบจำลองทุกประเภทสามารถระบุเห็ดพิษได้อย่างถูกต้องทั้งหมด กล่าวคือ เมื่อแบบจำลองพยากรณ์ว่าเห็ดเป็นพิษ จะไม่มีกรณีที่เห็ดกินได้ถูกจำแนกผิดเป็นเห็ดพิษ (Zero False Positive) ซึ่งช่วยลดความเสี่ยงในการตัดสินใจผิดพลาดในกระบวนการจำแนกเห็ด

- **Recall = 0.98 (98%)**

แบบจำลองสามารถตรวจจับเห็ดพิษได้ครอบคลุมประมาณร้อยละ 98 ของข้อมูลทั้งหมด แม้จะมีกรณีที่เห็ดพิษบางส่วนไม่ได้ถูกตรวจจับ แต่ยังถือว่าอยู่ในระดับประสิทธิภาพที่สูงสำหรับระบบช่วยตัดสินใจเบื้องต้น

**การวิเคราะห์ความเสถียรของแบบจำลอง (Model Stability)**

แม้ว่าแบบจำลองทั้งสามจะให้ค่าความแม่นยำสุดท้ายเท่ากันที่ 99.26% ในชุดข้อมูล Evaluation แต่เมื่อพิจารณาค่าความต่างระหว่างผลลัพธ์ของชุด Cross Validation และชุด Evaluation (Delta) พบความแตกต่างเล็กน้อยดังนี้

- **XGBoost** และ **Neural Network** มีค่า Delta ต่ำที่สุดที่ 0.0019
- **kNN** มีค่า Delta เท่ากับ 0.0022

ค่าความต่างที่ต่ำมากในทุกแบบจำลองสะท้อนให้เห็นว่าแบบจำลองสามารถรักษาประสิทธิภาพได้ดีเมื่อเผชิญกับข้อมูลใหม่ และไม่พบสัญญาณของปัญหา Overfitting อย่างชัดเจน

**เมทริกซ์ความสับสนของทั้ง 3 แบบจำลอง (Confusion Matrix Analysis)**

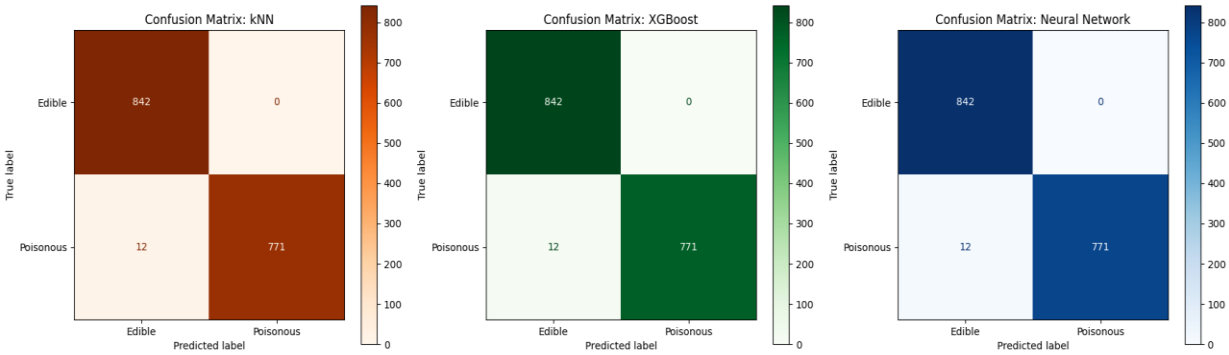


จากการพิจารณาเมทริกซ์ความสับสน (Confusion Matrix) ของชุดข้อมูลทดสอบจำนวน 1,625 ตัวอย่าง พบว่าแบบจำลองทั้งสาม ได้แก่ k-Nearest Neighbors (kNN), XGBoost และ Neural Network ให้รูปแบบการพยากรณ์ที่สอดคล้องกันอย่างชัดเจน โดยสามารถวิเคราะห์ผลลัพธ์ที่สำคัญได้ดังนี้

**1. ความแม่นยำด้านความปลอดภัยของการจำแนก (Zero False Positive)**

จากเมทริกซ์ความสับสนพบว่า ช่อง False Positive ของทุกโมเดลมีค่าเท่ากับ 0 หมายความว่าไม่มีกรณีที่ระบบพยากรณ์ว่าเห็ดเป็นพิษ (Poisonous) ทั้งที่จริงแล้วเป็นเห็ดกินได้ (Edible) ผลลัพธ์ดังกล่าวส่งผลให้ค่า Precision สำหรับคลาสเห็ดพิษเท่ากับ 1.00 (100%) ซึ่งถือว่าเป็นคุณสมบัติที่มีความสำคัญอย่างยิ่งในบริบทของการใช้งานจริง เนื่องจากช่วยป้องกันการแจ้งเตือนผิดพลาดที่อาจนำไปสู่การทิ้งเห็ดที่สามารถบริโภคได้โดยไม่จำเป็น

**2. การวิเคราะห์ความสามารถในการตรวจจับเห็ดพิษ (Recall Analysis)**

จากข้อมูลในเมทริกซ์ความสับสน พบว่าโมเดลสามารถจำแนก เห็ดพิษได้ถูกต้องจำนวน 771 ตัวอย่าง จากทั้งหมด 783 ตัวอย่าง และมีกรณีที่พยากรณ์ผิดเป็นเห็ดกินได้จำนวน 12 ตัวอย่าง (False Negative) ผลลัพธ์ดังกล่าวทำให้ค่า Recall สำหรับคลาสเห็ดพิษอยู่ที่ประมาณ 0.98 (98%) ซึ่งแสดงให้เห็นว่าแบบจำลองสามารถตรวจจับเห็ดพิษได้ครอบคลุมในระดับที่สูงมาก โดยมีเพียงส่วนน้อยเท่านั้นที่หลุดรอดจากการตรวจจับ

**การสรุปผลและการคัดเลือกแบบจำลองที่เหมาะสมที่สุด**

จากการเปรียบเทียบประสิทธิภาพของแบบจำลองทั้งสามประเภท พบว่าแม้ทุกอัลกอริทึมจะให้ค่าความแม่นยำใกล้เคียงกัน แต่เมื่อพิจารณาปัจจัยด้านโครงสร้างของโมเดล การใช้ทรัพยากร และความเหมาะสมต่อการนำไปใช้งานจริง สามารถสรุปได้ว่า **XGBoost** เป็นแบบจำลองที่เหมาะสมที่สุดสำหรับโครงงานนี้ โดยมีเหตุผลสำคัญดังต่อไปนี้

**1. ความเสถียรของแบบจำลอง** XGBoost มีค่าความต่างระหว่างชุด Cross Validation และ Evaluation ต่ำ (Delta = 0.0019) แสดงให้เห็นว่าแบบจำลองสามารถรักษาระดับประสิทธิภาพได้ดีเมื่อนำไปใช้กับข้อมูลใหม่ ซึ่งเป็นคุณสมบัติสำคัญของโมเดลที่นำไปใช้งานจริง

**2. ประสิทธิภาพในการประมวลผล** เมื่อเปรียบเทียบกับ kNN ซึ่งต้องเก็บข้อมูลฝึกสอนทั้งหมดไว้เพื่อคำนวณระยะห่าง XGBoost จัดเก็บเพียงโครงสร้างของต้นไม้ตัดสินใจ ทำให้ใช้หน่วยความจำต่ำกว่าและสามารถประมวลผลการพยากรณ์ได้รวดเร็วกว่า

**3. ความเหมาะสมกับลักษณะของข้อมูล** ชุดข้อมูลที่ใช้ในการทดลองเป็นข้อมูลแบบตาราง (Tabular Data) โดยทั่วไปอัลกอริทึมในกลุ่ม Gradient Boosting Decision Trees (GBDT) เช่น XGBoost มักให้ผลลัพธ์ที่มีประสิทธิภาพสูงกับข้อมูลประเภทนี้ เนื่องจากสามารถเรียนรู้ความสัมพันธ์เชิงตรรกะของคุณลักษณะได้อย่างมีประสิทธิภาพ

**4. ความเหมาะสมต่อการนำไปประยุกต์ใช้งาน** ด้วยค่าความแม่นยำสูงร่วมกับโครงสร้างโมเดลที่ไม่ซับซ้อนมาก ทำให้ XGBoost มีความเหมาะสมสำหรับการนำไปพัฒนาเป็นระบบช่วยตัดสินใจเบื้องต้น เช่น ระบบจำแนกประเภทเห็ดบนอุปกรณ์พกพา หรือระบบสนับสนุนการตัดสินใจด้านความปลอดภัยของอาหาร

**รายการอ้างอิง**

UCI Machine Learning. (2016). *Mushroom Classification.* Kaggle.
https://www.kaggle.com/datasets/uciml/mushroom-classification

**ภาคผนวก**

**ตารางคำอธิบายเกี่ยวกับชุดข้อมูล**

ชุดข้อมูล Mushroom Dataset ประกอบด้วยข้อมูลลักษณะทางกายภาพของเห็ดจำนวน 23 คุณลักษณะ (Attributes) ซึ่งใช้ในการจำแนกประเภทของเห็ดว่าเป็นเห็ดที่สามารถรับประทานได้หรือเป็นเห็ดพิษ โดยข้อมูลแต่ละคอลัมน์เป็นข้อมูลเชิงหมวดหมู่ (Categorical Data) ที่ถูกแทนค่าด้วยตัวอักษรเพื่อแสดงลักษณะเฉพาะของเห็ดในแต่ละด้าน ดังรายละเอียดต่อไปนี้

**1. class (ประเภทของเห็ด)** ใช้ระบุประเภทของเห็ด เป็นตัวแปรเป้าหมายของการจำแนก

| ค่า | ความหมาย |
|---|---|
| p | poisonous (เห็ดมีพิษ) |
| e | edible (เห็ดรับประทานได้) |

**2. cap-shape (ลักษณะรูปทรงของหมวกเห็ด)** ใช้ระบุลักษณะรูปร่างของหมวกเห็ด

| ค่า | ความหมาย |
|---|---|
| b | bell (รูปกระดิ่ง) |
| c | conical (รูปกรวย) |
| x | convex (นูนโค้ง) |
| f | flat (แบน) |
| k | knobbed (มีก้อนปุ่ม) |
| s | sunken (เว้าลง) |

**3. cap-surface (ลักษณะพื้นผิวของหมวกเห็ด)** ใช้ระบุลักษณะพื้นผิวของหมวกเห็ด

| ค่า | ความหมาย |
|---|---|
| f | fibrous (เป็นเส้นใย) |
| g | grooves (มีร่อง) |
| y | scaly (เป็นเกล็ด) |
| s | smooth (เรียบ) |

**4. cap-color (สีของหมวกเห็ด)** ใช้ระบุสีของหมวกเห็ด

| ค่า | ความหมาย |
|---|---|
| n | brown (สีน้ำตาล) |
| b | buff (สีน้ำตาลอ่อน) |
| c | cinnamon (สีอบเชย) |
| g | gray (สีเทา) |
| r | green (สีเขียว) |
| p | pink (สีชมพู) |
| u | purple (สีม่วง) |
| e | red (สีแดง) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**5. bruises (การเกิดรอยช้ำ)** ใช้ระบุว่าเห็ดมีการเกิดรอยช้ำเมื่อถูกสัมผัสหรือไม่

| ค่า | ความหมาย |
|---|---|
| t | bruises (มีรอยช้ำ) |
| f | no (ไม่มีรอยช้ำ) |

**6. odor (กลิ่นของเห็ด)** ใช้ระบุลักษณะกลิ่นของเห็ด

| ค่า | ความหมาย |
|---|---|
| a | almond (กลิ่นอัลมอนด์) |
| l | anise (กลิ่นโป๊ยกั๊ก) |
| c | creosote (กลิ่นครีโอโซต) |
| y | fishy (กลิ่นคาวปลา) |
| f | foul (กลิ่นเหม็น) |
| m | musty (กลิ่นอับ) |
| n | none (ไม่มีกลิ่น) |
| p | pungent (กลิ่นฉุน) |
| s | spicy (กลิ่นเครื่องเทศ) |

**7. gill-attachment (ลักษณะการติดของครีบเห็ด)** ใช้ระบุลักษณะการติดของครีบเห็ดกับก้าน

| ค่า | ความหมาย |
|---|---|
| a | attached (ติดกับก้าน) |
| d | descending (ยื่นลงตามก้าน) |
| f | free (ไม่ติดก้าน) |
| n | notched (มีรอยเว้า) |

**8. gill-spacing (ระยะห่างของครีบเห็ด)** ใช้ระบุระยะห่างระหว่างครีบเห็ด

| ค่า | ความหมาย |
|---|---|
| c | close (ชิดกัน) |
| w | crowded (แน่นมาก) |
| d | distant (ห่างกัน) |

**9. gill-size (ขนาดของครีบเห็ด)** ใช้ระบุขนาดของครีบเห็ด

| ค่า | ความหมาย |
|---|---|
| b | broad (กว้าง) |
| n | narrow (แคบ) |

**10. gill-color (สีของครีบเห็ด)** ใช้ระบุสีของครีบเห็ด

| ค่า | ความหมาย |
|---|---|
| k | black (สีดำ) |
| n | brown (สีน้ำตาล) |
| b | buff (สีน้ำตาลอ่อน) |
| h | chocolate (สีน้ำตาลช็อกโกแลต) |
| g | gray (สีเทา) |
| r | green (สีเขียว) |
| o | orange (สีส้ม) |
| p | pink (สีชมพู) |
| u | purple (สีม่วง) |
| e | red (สีแดง) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**11. stalk-shape (ลักษณะรูปทรงของก้านเห็ด)** ใช้ระบุรูปทรงของก้านเห็ด

| ค่า | ความหมาย |
|---|---|
| e | enlarging (ก้านใหญ่ขึ้นด้านล่าง) |
| t | tapering (ก้านเรียวลง) |

**12. stalk-root (ลักษณะรากของก้านเห็ด)** ใช้ระบุลักษณะส่วนฐานของก้านเห็ด

| ค่า | ความหมาย |
|---|---|
| b | bulbous (เป็นกระเปาะ) |
| c | club (เป็นรูปกระบอง) |
| u | cup (เป็นถ้วย) |
| e | equal (ขนาดเท่ากัน) |
| z | rhizomorphs (มีเส้นใยราก) |
| r | rooted (มีรากยาว) |
| ? | missing (ไม่มีข้อมูล) |

**13. stalk-surface-above-ring (พื้นผิวก้านเห็ดเหนือวงแหวน)**

| ค่า | ความหมาย |
|---|---|
| f | fibrous (เป็นเส้นใย) |
| y | scaly (เป็นเกล็ด) |
| k | silky (เรียบลื่นคล้ายไหม) |
| s | smooth (เรียบ) |

**14. stalk-surface-below-ring (พื้นผิวก้านเห็ดใต้วงแหวน)**

| ค่า | ความหมาย |
|---|---|
| f | fibrous (เป็นเส้นใย) |
| y | scaly (เป็นเกล็ด) |
| k | silky (เรียบลื่นคล้ายไหม) |
| s | smooth (เรียบ) |

**15. stalk-color-above-ring (สีก้านเห็ดเหนือวงแหวน)**

| ค่า | ความหมาย |
|---|---|
| n | brown (สีน้ำตาล) |

| | |
|---|---|
| b | buff (สีน้ำตาลอ่อน) |
| c | cinnamon (สีอบเชย) |
| g | gray (สีเทา) |
| o | orange (สีส้ม) |
| p | pink (สีชมพู) |
| e | red (สีแดง) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**16. stalk-color-below-ring (สีก้านเห็ดใต้วงแหวน)**

| ค่า | ความหมาย |
|---|---|
| n | brown (สีน้ำตาล) |
| b | buff (สีน้ำตาลอ่อน) |
| c | cinnamon (สีอบเชย) |
| g | gray (สีเทา) |
| o | orange (สีส้ม) |
| p | pink (สีชมพู) |
| e | red (สีแดง) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**17. veil-type (ประเภทของเยื่อหุ้มเห็ด)**

| ค่า | ความหมาย |
|---|---|
| p | partial (เยื่อหุ้มบางส่วน) |
| u | universal (เยื่อหุ้มทั้งหมด) |

**18. veil-color (สีของเยื่อหุ้มเห็ด)**

| ค่า | ความหมาย |
|---|---|
| n | brown (สีน้ำตาล) |
| o | orange (สีส้ม) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**19. ring-number (จำนวนวงแหวนบนก้านเห็ด)**

| ค่า | ความหมาย |
|---|---|
| n | none (ไม่มี) |
| o | one (หนึ่งวง) |
| t | two (สองวง) |

**20. ring-type (ประเภทของวงแหวน)**

| ค่า | ความหมาย |
|---|---|
| c | cobwebby (คล้ายใยแมงมุม) |
| e | evanescent (จางหายง่าย) |
| f | flaring (บานออก) |
| l | large (ขนาดใหญ่) |
| n | none (ไม่มี) |
| p | pendant (ห้อยลง) |
| s | sheathing (หุ้มก้าน) |
| z | zone (เป็นแถบ) |

**21. spore-print-color (สีของผงสปอร์)**

| ค่า | ความหมาย |
|---|---|
| k | black (สีดำ) |
| n | brown (สีน้ำตาล) |
| b | buff (สีน้ำตาลอ่อน) |
| h | chocolate (สีน้ำตาลช็อกโกแลต) |
| r | green (สีเขียว) |
| o | orange (สีส้ม) |
| u | purple (สีม่วง) |
| w | white (สีขาว) |
| y | yellow (สีเหลือง) |

**22. population (ความหนาแน่นของเห็ดในพื้นที่)**

| ค่า | ความหมาย |
|---|---|
| a | abundant (มีจำนวนมาก) |
| c | clustered (ขึ้นเป็นกลุ่ม) |
| n | numerous (จำนวนมาก) |
| s | scattered (กระจาย) |
| v | several (มีหลายดอก) |
| y | solitary (ขึ้นเดี่ยว) |

**23. habitat (สภาพแวดล้อมที่พบเห็ด)**

| ค่า | ความหมาย |
|---|---|
| g | grasses (ทุ่งหญ้า) |
| l | leaves (กองใบไม้) |
| m | meadows (ทุ่งหญ้าโล่ง) |
| p | paths (ตามทางเดิน) |
| u | urban (เขตเมือง) |
| w | waste (พื้นที่รกร้าง) |
| d | woods (ป่าไม้) |

ภาพของโค้ดการวิเคราะห์คุณลักษณะที่สำคัญ (Feature Importance) และผลลัพธ์ที่ได้

```python
# 1. สร้างโมเดล Random Forest
rf = RandomForestClassifier(n_estimators=200, random_state=42)
rf.fit(X, y)

# 2. คำนวณ Permutation Importance
result = permutation_importance(rf, X, y, n_repeats=30, random_state=42)

# 3. สร้าง DataFrame สรุปผลคุณลักษณะทั้งหมด
importance_df = pd.DataFrame({
    'feature': X.columns,
    'importance': result.importances_mean,
    'std_dev': result.importances_std
})

# เรียงลำดับตามความสำคัญ
importance_df = importance_df.sort_values(by='importance', ascending=False).reset_index(drop=True)

# เพิ่มคอลัมน์ลำดับ (Rank)
importance_df.insert(0, 'rank', importance_df.index + 1)

# สร้าง mapping ชื่อคอลัมน์ → ลำดับคอลัมน์เดิมใน dataset
original_column_index = {col: idx+1 for idx, col in enumerate(X.columns)}
importance_df["original_column_no"] = importance_df["feature"].map(original_column_index)

# จัดเรียงคอลัมน์ให้อ่านง่าย
importance_df = importance_df[["rank", "feature", "original_column_no", "importance", "std_dev"]]

# 4. แสดงผลลัพธ์
print("--- ลำดับความสำคัญของคุณลักษณะทั้งหมด (Feature Importance Ranking) ---")
print(importance_df.to_string(index=False))

# 5. วิเคราะห์ผลลัพธ์ Top 3 Features
top_3 = importance_df.head(3)

print("\n--- ผลลัพธ์ Top 3 Features ---")
for _, row in top_3.iterrows():
    print(f"Rank {row['rank']}: {row['feature']} "
          f"(คอลัมน์เดิมลำดับที่ {row['original_column_no']}) "
          f"(Score: {row['importance']:.6f})")
```

```
--- ลำดับความสำคัญของคุณลักษณะทั้งหมด (Feature Importance Ranking) ---
 rank                 feature  original_column_no  importance  std_dev
    1                    odor                   5    0.006955 0.000668
    2               gill-size                   8    0.002827 0.000304
    3        spore-print-color                 19    0.001083 0.000245
    4               cap-shape                   1    0.000000 0.000000
    5             cap-surface                   2    0.000000 0.000000
    6                 bruises                   4    0.000000 0.000000
    7               cap-color                   3    0.000000 0.000000
    8            gill-spacing                   7    0.000000 0.000000
    9         gill-attachment                   6    0.000000 0.000000
   10             stalk-shape                  10    0.000000 0.000000
   11              stalk-root                  11    0.000000 0.000000
   12 stalk-surface-above-ring                  12    0.000000 0.000000
   13               gill-color                   9    0.000000 0.000000
   14 stalk-surface-below-ring                  13    0.000000 0.000000
   15   stalk-color-above-ring                  14    0.000000 0.000000
   16               veil-color                  16    0.000000 0.000000
   17   stalk-color-below-ring                  15    0.000000 0.000000
   18             ring-number                   17    0.000000 0.000000
   19               ring-type                   18    0.000000 0.000000
   20              population                   20    0.000000 0.000000
   21                 habitat                   21    0.000000 0.000000

--- ผลลัพธ์ Top 3 Features ---
Rank 1: odor (คอลัมน์เดิมลำดับที่ 5) (Score: 0.006955)
Rank 2: gill-size (คอลัมน์เดิมลำดับที่ 8) (Score: 0.002827)
Rank 3: spore-print-color (คอลัมน์เดิมลำดับที่ 19) (Score: 0.001083)
```